

# Visibility Graphs For Image Processing

EMİNE AKDUMAN

Fırat Üniversitesi Lisans Öğrencisi

[eakdmn@gmail.com](mailto:eakdmn@gmail.com)

Türkiye, Elâzığ


**Özet—** Bu bölümde, IVG/IHVG'lerin topolojik grafları filtreler olarak kullanılması gösterildi. Temel 3 filtre olarak *k-filtre*, *C-filtre*, *Knn filtre* yöntemleri ve özellikleri üzerinde duruldu.

**Anahtar Kelimeler—** *k-filtre*, *C-filtre*, *Knn filtre*

## 1. GÖRÜNÜRLÜK FİLTRESİ(VISIBILITY FILTER)

$I_{ij} \in \mathbb{R}$  olan  $N \times N$  bir matris ele alalım. Görünürlük filtrelenmiş görüntüyü veya sadece görünürlük filtresi  $F_{VG}(I)$ ,  $i, j$  ögesi derecesi veya kümeleme katsayısı gibi ilişkili IVG'nin  $i, j$  düğümünün belirli bir düğüm özelliğinin değerine karşılık gelen bir  $N \times N$  matrisi olarak tanımlarız. İlişkili IVG, derecesi veya kümeleme katsayısı gibi. Özellik gerçek bir skaler miktar ise, bu miktar gri tonlamalı tamsayı değerlerine uygun şekilde ölçeklendirilir. Yatay görünürlük filtresi  $F_{HVG}(I)$  ise yukarıdaki tanımla eşdeğer diyebiliriz. Görünürlük filtresinin yukarıdaki tanımı, karşılaştırılabilir aralıklarda farklı düğüm özellikleri arasında karşılaştırmaya izin veren önemsiz bir ölçekleme ile belirli bir topolojik grafa indirgenir. Bir priori, bu tür filtreleri tanımlamak için birçok farklı düğüm özelliğini kullanabilir, burada üç  $F_{HVG}(I)$  filtresini tanımlamak için en basit özelliklerden üçüne, yani derece, kümeleme ve derece-dereceye odaklanıyoruz:


- **k-filtre:**  $i, j$ 'ye  $i, j$  düğümünün derecesini atadığımızda. Burada yeniden ölçekleme gerekmez.
- **C-filtre:**  $i, j$ 'ye,  $i, j$  düğümünün yerel kümeleme katsayısını ( $\{0,255\}$  olarak ölçeklendirilmiş) atadığımızda.
- **Knn-filtre:**  $i, j$ 'ye,  $i, j$  düğümünün ortalama en yakın komşu derecesinden en yakın tamsayı değerini atadığımızda.



Şekil 1. Lena'ya uygulanan çeşitli görünürlük filtreleri  $F_{HVG}$  (filtrelenmiş görüntülerde kontrastı dengelemek için bir histogram denkleştirme uyguladık).

Örnek için, Şek. 1'de orijinal gri tonlamalı Lena görüntüsünü ( $512 \times 512$ ) üç HVG filtresiyle birlikte çiziyoruz (histogram dengeleme *k-filtresine* ve *Knn-filtresine* uygulandı ve *C-filtresi*, ayrıntıların daha iyi görselleştirilmesini sağlamak için ters gri tonlamalı olarak çizildi). Birkaç  $512 \times 512$  standart gri tonlama görüntülerine bağlı *k-filtrelerin* ek örnekleri (histogram eşitlenmiş) Şekil 2'de görüntülenir. Her iki şekle de bakıldığında ilk gözlem, bu filtrelerin klasik kenar algılama filtreleriyle (örneğin, Sobol, Canny, entropi filtreleri) bazı benzerlikleri paylaşmasıdır. Bununla birlikte,

kenar algılama filtreleriyle çelişirken, bizim durumumuzda görüntünün ek ince bilgisi korunuyor gibi görünüyor. Aslında birçok önemli detayın (örneğin Lena'nın yüzündeki ve şapkadaki detaylar) hala tanınabilir olduğunu ve özellikle görüntünün dokusunun bir şekilde korunduğunu fark etmek kolaydır.



Şekil 2. IHVG k-filtresi ile birlikte literatürde sıklıkla bulunan 512x512 standart gri tonlama görüntüleri kümesi.

### 1.1 Boyut Küçültme

Gri tonlamada, genel bir kare görüntü  $N^2$  piksele sahiptir ve her piksel  $2^8$  değer alabilir, böylece görüntü boyutu  $|I|=n^2$  bayttır. IHVG k-filtresinde, her piksel şimdi ilişkili düğümün  $k$  derecesine karşılık gelir.

IHVG'nin inşa ederek, sınır etkilerini ihmal ederek,  $8 \leq k \leq N^2 - 1$ 'e sahip olduğumuzu biliyoruz.

$$P(k < K) = \sum_{k=K}^{\infty} \left(\frac{1}{9}\right) \left(\frac{8}{9}\right)^{k-8} = \left(\frac{8}{9}\right)^{k-8}$$

Büyüklik sırası hakkında bir fikir vermek için,  $k = 24$  için, bu olasılık kabaca 0.15'tir, yani 24'ten daha büyük bir dereceye sahip beklenen düğüm sayısı yaklaşık yüzde 15'tir. Başka bir deyişle, derecenin bilgisini kesmeye ve derecesi

24'e eşit veya daha büyük olan tüm düğümler için  $k = 24$  atamaya karar verirsek, etkili bir şekilde beyaz bir parazit görüntüsünün  $k$  filtresindeki piksellerin sadece yüzde 15'ini doyururduk. Genel olarak, beyaz bir parazit görüntüsü için doymuş piksellerin yüzdesi basitçe;

$$SP(k) = 100 \left(\frac{8}{9}\right)^{k-8}$$

Derece üzerinde herhangi bir kesme ayarlanmamışsa, herhangi bir  $k < N^2 - 1$  için  $k$  derecesine sahip bir düğüm bulma olasılığı katlanarak yok olur (sıfır olmasa da).

Uygulamada,  $k < N^2 - 1$  kesme değerini ayarlayarak, tasarım gereği filtrelenmiş görüntünün boyutu aşağıdaki gibi olacaktır:

$$|F_{HVG}(I)| = \frac{\log_2 k - 8}{8} N^2 \text{ bytes.}$$

$K = 24$  için sadece  $N^2/2$  baytına ihtiyacımız olduğunu unutmayın, bu nedenle minimum bozulma ile faktör 2 boyutunda bir azalmaya sahibiz. Redüksiyon faktörü  $RF(k)$  'nin tanımlanması;

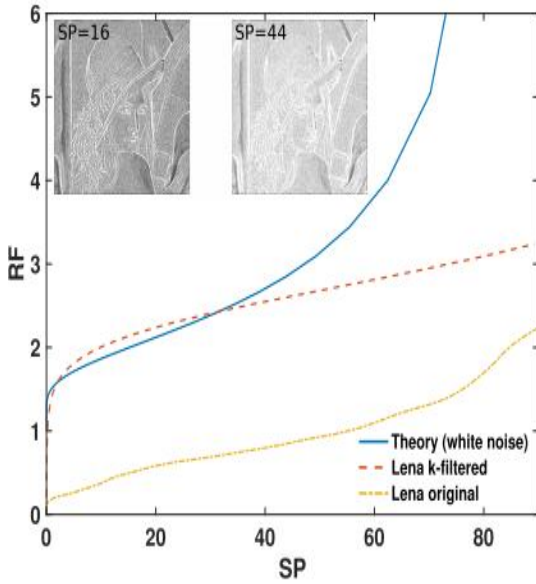
$$RF(k) = \frac{|I|}{|F_{HVG}(I)|} = \frac{8}{\log_2(k-8)},$$

teorik analizimiz, beyaz parazit görüntüleri durumunda RF-SP düzlemi için analitik bir ilişki öngörmektedir:

$$RF = \frac{8}{\log_2(\log(SP/100)/\log(8/9))}$$

Şimdi, en azından 1D (zaman serisi) versiyonunda, HVG'lerin derece dağılımının tipik durumda (sadece beyaz parazit için değil) katlanarak bozulduğu bilinmektedir, bu yüzden benzer bir davranışın görüntü ayarında gerçekleşmesini bekleriz ve bu nedenle büyük dereceler bulma olasılığı, genel olarak, katlanarak küçüktür. Şek. 3'de k-filtrelenmiş Lena üzerinde deneysel sonuçlarla birlikte teorik eğri için RF-SP düzlemini çiziyoruz. Karşılaştırma için, orijinal Lena görüntüsüne benzer bir doyumluk prosedürü uygulanır ve sonuçlar da gösterilir. Filtrelenmiş görüntünün orijinal görüntüden daha büyük bir boyut azaltımına izin verdiğini ve doyma yüzdesinin büyük değerleri için bile doymuş filtrelenmiş

görüntüdeki Lena'yı açıkça tanımlayabildiğini görebiliriz.

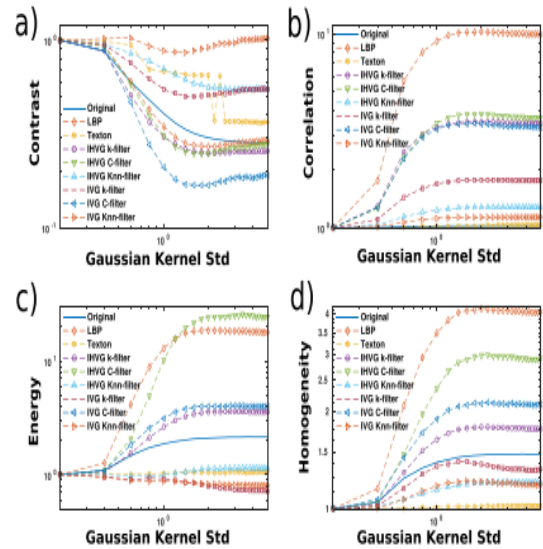


Şekil 3. Beyaz parazit görüntüsü (düz mavi çizgi) ve Lena (kahverengi kesik çizgi) üzerinde  $k$ -filtresi ile elde edilen doymuş piksel (SP) yüzdesi işlevinde azaltma faktörü (RF). RF-SP eğrisi, karşılaştırma için filtresiz (noktalı sarı çizgi) lena örneğinde de gösterilir.

## 1.2 Görüntü Ön İşlemi için IHVG Filtreleri: Karşılaştırma

Görüntü işlemede standart bir problem düşünün: görsel yüz tanıma. Özellik tabanlı sınıflandırmada kanonik yaklaşım, her görüntüden bir özellik vektörünün çıkarılmasını ve daha sonra denetimli öğrenme için sınıflandırıcıları bu vektörlerle beslemeyi içerir. Bazı durumlarda, görüntüler önceden işlenirse (yani, özellik çıkarılmadan önce) sınıflandırıcının performansı geliştirilebilir. Örneğin yerel ikili desenler, monotonik gri tonlama varyasyonlarına karşı dayanıklı olan, genellikle görüntülerin farklı aydınlatma koşullarında veya farklı çözünürlüklerde çekildiği gerçeğinin üstesinden gelmek için yüz tanıma problemlerinde yaygın olarak kullanılmaktadır. Burada, görüntü dokusu analizinin iyileştirilmesi için yukarıda ön işleme filtreleri olarak tanımlanan farklı IVG / IHVG filtrelerinin potansiyelini test ediyoruz. Gerçek

dünya edinim değişkenliğini simüle etmek için, Lena'nın bir görüntüsünü, standart sapma değerlerine sahip 5x5 Gaussian çekirdeğini orijinal görüntüye uygulayarak farklı çözünürlük ölçeklerine dönüştürüyoruz. Standart özellik çıkarma yöntemi olarak, daha sonra iyi bilinen bir doku analizi tekniği olan gri düzey birlikte oluşum matrisini (GLCM) kullanırız. Belirli bir çözünürlük için (çekirdek std değeri) GLCM görüntüden hesaplanır ve haralick olarak adlandırılan dört özellik ayıklanır: Kontrast (yerel varyasyonların ölçümü), Korelasyon (çiftlerin ortak olasılık oluşumunu ölçme), Enerji (matrisin kareli elemanlarının toplamı) ve Homojenlik (matristeki elementlerin çaprazına dağılımının yakınlığını ölçme). Tüm görüntüler daha sonra uygun şekilde normalize edilmiş Haralick özellikleriyle yayılan 4 boyutlu uzaydaki noktalara eşlenir (bkz. Şekil 4).

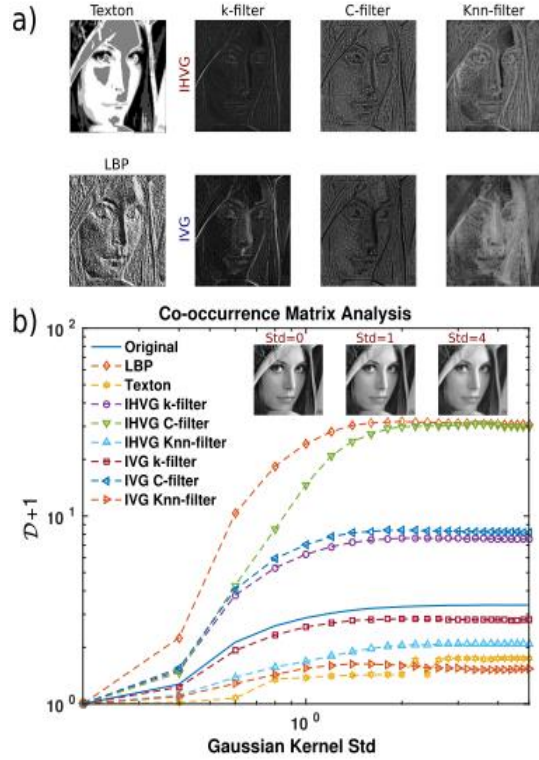


Şekil 4. Haralick, farklı varyanstaki Gaussian çekirdekleri uygulandığında Lena görüntüden çıkarılan Kontrast, Korelasyon, Enerji ve Homojenlik özellikleridir ve ekstraksiyondan önce görüntüyü önceden işlemek için farklı IHVG/IVH filtreler kullanılır. Özelliklerin tümü orijinal görüntünün değerine göre normalize edilmiş (yeniden ölçeklendirilir) (Gaussian çekirdeği std = 0).

Düşük çözünürlüklü görüntüler ile orijinal görüntü arasındaki  $d$  mesafesi daha sonra hesaplanır. Sezgisel olarak,  $D$  ne kadar düşükse, düşük çözünürlüklü görüntüsü, özellik alanındaki yüksek çözünürlüklü versiyonundan



daha benzerdir ve buna göre, yüksek çözünürlüklü versiyonla eğitilmiş bir sınıflandırıcı, düşük çözünürlüklü görüntüleri doğru bir şekilde sınıflandırmak için daha az zorluk bulacaktır. Prosedür, (i) filtrelenmemiş görüntü için ve (ii) altı görünürlük filtresinin tümünü (IVG ve IHVG için k-filtre, Knn-filtre ve C-filtre) kullanarak filtrelenmiş görüntüler için birkaç kez tekrarlanır.



Şekil 4. Görüntü ön işlemede IVG/IHVG filtrelerinin performansı. a) IVG ve IHVG filtreleri, Lena yüz görüntüsüne uygulanan LBP (yerel ikili desenler) filtresi ve Texton filtresi ile birlikte gösterilir. B) Lena yüz görüntüsü ile farklı çözünürlük ölçeklerinde aynı görüntü arasındaki mesafe  $D$ , (normalleştirilmiş) Haralick özelliklerinin 4 boyutlu uzayında ölçülür ve düşük çözünürlüklü görüntüler elde etmek için uygulanan Gauss  $5 \times 5$  çekirdeğinin standart sapmasının bir fonksiyonu olarak çizilir.  $D$ , orijinal filtrelenmemiş görüntü için ve a) 'da gösterilen filtreler kullanılarak önceden işlendikten sonra aynı görüntü için hesaplanır.  $D$ , filtrelerin ön işlemciler olarak performansının bir göstergesidir.

Sonuçlar şek. 5'de b, burada log-log  $d + 1$ 'de çekirdek standart sapmasının bir fonksiyonu olarak çiziyoruz (yani, bu parametre ne kadar büyük olursa, görüntünün çözünürlüğü o kadar düşük olur). Aynı şekilde a) panelinde, Lena yüzündeki analizde kullanılan farklı filtreler için filtre etkisi gösterilmiştir. Hem IVG hem de IHVG Knn-filtreleri durumunda, IVG k-filtresi ve Texton filtresi, D'nin filtrelenmemiş görüntü için sistematik olarak görüldüğünü ve tüm düşük çözünürlüklü görüntülerin sistematik olarak daha yakın olacağını öne sürdüğünü görüyoruz.

## REFERANSLAR

- [1]. J. Iacovacci and L. Lacasa, "Visibility Graphs for Image Processing," in *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 4, pp. 974-987, 1 April 2020, doi: 10.1109/TPAMI.2019.2891742.
- [2]. <https://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.379.9420&rep=rep1&type=pdf>
- [3]. N. Ahmadi and M. Pechenizkiy, "Application of Horizontal Visibility Graph as a Robust Measure of Neurophysiological Signals Synchrony," 2016 IEEE 29th International Symposium on Computer-Based Medical Systems (CBMS), Dublin, 2016, pp. 273-278, doi: 10.1109/CBMS.2016.73.
- [4]. H. Kaluder, M. Brezak and I. Petrović, "A visibility graph based method for path planning in dynamic environments," 2011 Proceedings of the 34th International Convention MIPRO, Opatija, 2011, pp. 717-721.
- [5]. [https://www.researchgate.net/publication/221926613\\_Visibility\\_Algorithms\\_A\\_Short\\_Review](https://www.researchgate.net/publication/221926613_Visibility_Algorithms_A_Short_Review)
- [6]. [https://www.researchgate.net/figure/Visibility-and-co-visibility-information-a-Visibility-graph-The-original-graph\\_fig2\\_322566686](https://www.researchgate.net/figure/Visibility-and-co-visibility-information-a-Visibility-graph-The-original-graph_fig2_322566686)
- [7]. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4646626/>

*[8].<https://www.rankranger.com/documentation/visibility-graph>*

*[9].<https://link.springer.com/article/10.1186/1687-6180-2012-220>*

*[10].<https://www.sciencedirect.com/science/article/abs/pii/S0378437119312968>*

