

# Visibility Graphs For Image Processing

EMİNE AKDUMAN

Fırat Üniversitesi Lisans Öğrencisi

[eakdmn@gmail.com](mailto:eakdmn@gmail.com)

Türkiye, Elâzığ

**Özet—** Bu bölümde bilgisayar görüşünde klasik bir sorun olan doku algılama ve sınıflandırma görevi için bunların uygulanabilirliğini verimli ve evrensel özellik çıkarma yöntemleri olarak dönüştürüp yöntemlerini araştırıldı.

**Anahtar Kelimeler—** Örüntü, Doku Sınıflandırması, Malzeme Dokusu

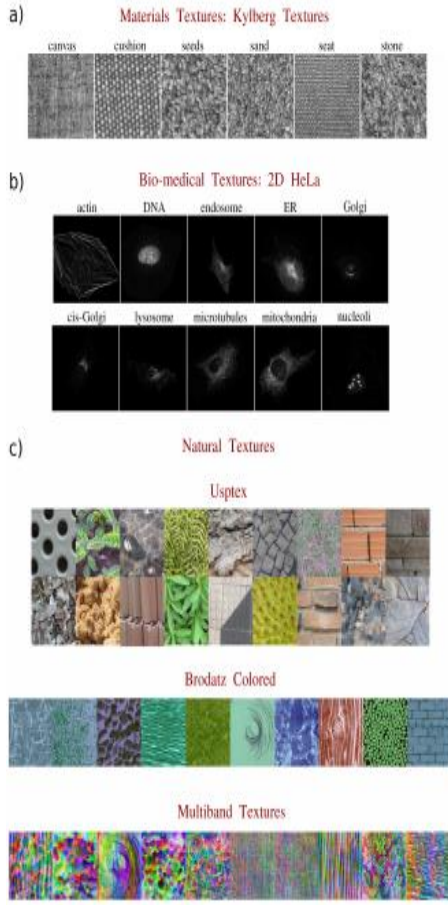
## 1. ÖRÜNTÜ TANIMA VE DOKU SINIFLANDIRMASI

Kapsamlı bir matematiksel doku tanımı yaygın olarak kabul edilmese de, dokular sezgisel olarak görüntülerdeki piksel yoğunluğu değerlerinin mekânsal dağılımından kaynaklanan karakteristik görsel desenler olarak tanımlanabilir ve bu nedenle, nesne izleme, yüz tanıma ve otomatik tıbbi teşhis gibi birçok makine görme uygulamasında temel öneme sahiptirler. Doku ve doku ile ilgili veri kümelerini kataloglama yönündeki son çabaların ardından, görüntü görünürlüğü ile ilgili tanımlayıcıların performansını farklı doku türleri, yani malzeme dokuları, biyo-tıbbi dokular ve doğal dokular üzerinde test edilecek.

### 1.2 Malzeme Dokusu Tanıma İçin Genel Özellikler

IVG veya IHVG' den çıkarılan  $P(k)$  derecesinin dağılımının, malzeme dokularını otomatik olarak tanımak için ideal bir genel özellik vektörü olduğunu tanımlayarak başlıyoruz. Bu arada, belirli bir görüntüyle ilişkili bir IVG veya IHVG derece dağılımının matematiksel olarak görüntünün k-filtresinin piksel yoğunluğu histogramına eşdeğer olduğunu gözlemleyelim, bu nedenle sınıflandırma amacıyla  $P(k)$  kullanmak aynı amaç için k-filtrenin temel özelliklerini (yoğunluk histogramı) kullanmaya eşdeğerdir. LBP ve Texton filtrelerinden elde

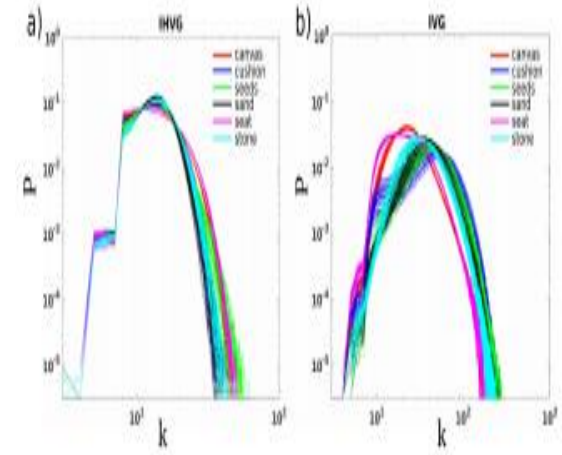
edilen sonuçlarla karşılaştırıyoruz. Malzeme dokuları, bu şekilde yakalanan karakteristik yapısal desenlere göre sınıflandırmak amacıyla çeşitli malzeme türlerinin yüzeyini görüntüleyerek elde edilen belirli bir doku sınıfıdır. Kullanılan veri seti, sınıf başına 40 örnek içeren 6 farklı malzemeden (tuval yüzeyi, yastık yüzeyi, çizgi tohumları, kum, koltuk yüzeyi ve taş yüzeyi) gri tonlamalı doku görüntülerinden oluşan Kylberg doku veri setinin azaltılmış bir versiyonudur. Görüntülerin gri tonlamalı doğası ve malzemelerin düzgün dokusu nedeniyle, bu, IVG/IHVG küresel özelliklerinin yüzey yapısal korelasyonlarını ve desenlerini yakalama yeteneğini test etmek için idealdir. Şekil 1a'da doku sınıflarının bir örneğini sunuyoruz. Veri kümesindeki her görüntüye karşılık gelen IHVG'ye dönüştürülür ve derecesi dağılımı  $P(k)$  çıkarılır ve daha sonra girişte (özelliklerin bir vektörü olarak) farklı sınıflandırıcılara verilir. Temel bileşen analizi (PCA), özellik sayısını azaltmak ve nihai aşırı takmayı önlemek için giriş vektörlerine uygulanır ve 5 kat çapraz doğrulama prosedürü benimsenir. Doğru sınıflarına atanmış örnekleri yüzdesi olarak tanımlanan %100 sınıf (ortalama) sınıflandırma doğruluk bir Destek Vektör Makinesi (ovo-LSVM/qSVM bir doğrusal/karesel çekirdek bir Konuda, IHVG için ortalama IVG için karesel bir çekirdek ve SVM ile elde edilebilir).



Şekil 1. Doku tanımda görüntü görünürlüğü özelliklerinin kullanılabilirliğini doğrulamak için kullanılan veri kümeleri: a) kylbert azaltılmış veri kümesi, altı farklı malzemeden gri tonlamalı doku görüntüleri içerir. B) 2D HeLa, on organelle özgü proteinin gri tonlamalı floresan mikroskobu görüntülerini içerir. c) doğal doku Sınıflandırması görevi için üç veri kümesi kullanılır: Upstex veri kümesi, Brodatz renkli veri kümesi ve çok bantlı veri kümesi (MTB).

İlginç bir şekilde, bu doğruluk seviyesi sadece PCA projeksiyonunun ilk 5 ana bileşeni kullanılarak elde edilmiştir. Derece dağılımının neden bu kadar bilgilendirici bir özellik olduğunu daha fazla anlamak için, şekil 2'de IHVGs (a) ve IVGs (b) için tüm numuneler için

renklendirilmiş) derece dağılımını çiziyoruz. Dağılımlar sınıfa göre kümelenir ve zaten görsel inceleme ile kümeleri belirleyebilir



Şekil 2. A) tüm Ihvg'ler ve b) Kylberg doku veri kümesinin 6 sınıfından çıkarılan tüm Ivg'ler için  $p(k)$  derece dağılımlarının Log-log grafiği. Bu küresel özellikler, dokular arasındaki farkların çoğunu yakalayıp, doğrusal bir destek vektör makinesi kullanarak yüzde 100 sınıflandırma doğruluğuna ulaşıyor gibi görünmektedir (bkz. Tablo 1).

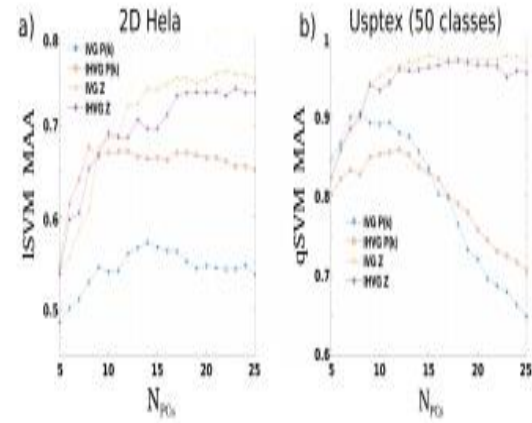
Tablo 1'de, MATLAB Sınıflandırması Öğrenci Uygulamasında uygulanan farklı standart sınıflandırıcılar tarafından ulaşılan sınıflandırma doğruluklarını rapor ediyoruz. IHVGs için, PCA uygulandıktan sonra karmaşık bir ağaç sınıflandırıcısı veya Torbalı bir ağaç kullanarak ve ağırlıklı bir KNN algoritması ile yüzde 100 doğruluk elde etmek mümkündür. Bütünlük için, aynı sınıflandırma görevinin sonuçlarını k filtremiz yerine standart filtreleri (LBP ve Texton) kullanarak da bildiririz. Sonuçlar LBP için eşit derecede iyidir ve Texton için performans düşer.

	Complex Tree	Linear Discriminant	linear SVM	quadratic SVM	weighted KNN	Ensemble Bagged Tree
IHVG P(k)	100%	96.7%	100%	100%	98.8%	100%
IHVG P(k)+PCA (5 PCs)	100%	96.7%	100%	100%	100%	99.2%
IVG P(k)	95.3%	95.8%	99.2%	100%	94.2%	98.8%
IVG P(k)+PCA (5 PCs)	96.7%	97%	97.9%	100%	100%	98.8%
LBP	95%	98.8%	100%	100%	100%	100%
LBP+PCA (5 PCs)	97.1%	99.2%	100%	100%	100%	98.3%
Texton	79.6%	74.2%	84.2%	93.3%	89.2%	86.2%

Tablo 1. Kullanılan sınıflandırıcılar, MATLAB Sınıflandırma Öğrenen Uygulaması'nda uygulanan standart sınıflayıcılardır. Derece dağılımı  $P(k)$  k-filtrenin yoğunluğu histogramı olarak anlaşılabilir ve karşılaştırma için standart LBP ve Texton filtrelerinin piksel yoğunluklarının histogramının ayıklanmasıyla elde edilen sonuçları içeririz.

### 1.3 Biyomedikal Doku Sınıflandırması için Genel ve Yerel Özelliklerin Birleştirilmesi

Bu bölümde, şimdi 2D HeLa adı verilen daha karmaşık bir görüntü veri kümesine odaklanıyoruz. Aktin, DNA, endozom, er, cis-Golgi, Golgi, lizozom, Mikrotübüller, mitokondri ve Nükleol: bu, proteinlerin karakteristik yapısal desenlerini ortaya çıkarabilen çeşitli organellere özgü floresan boyalarla boyanmış hela hücrelerinin gri tonlamalı floresan mikroskopi görüntülerinin biyo-tıbbi bir veri kümesidir. Bu sınıfların her biri için toplam 862 görüntü için farklı sayıda örnek görüntü vardır. Şekil 1b'de her sınıf için bir temsili örnek gösteriyoruz. Bu veri seti, işlevi hala bilinmeyen birçok genin karakterize edilmesine yardımcı olabilecek floresan mikroskop görüntülerinde alt hücrel protein kalıplarının otomatik olarak yorumlanmasının biyo-tıbbi zorluğuna göre örneklenmiştir. Malzeme dokularının aksine, bu görüntüler görüntünün yalnızca belirli bir alt bölgesini kaplayan birkaç karmaşık biyolojik yapı gösterir. Bu gerçek, sadece küresel özelliklerin kullanılmasını engelleyerek, bunları yüksek sınıflandırma doğrularına ulaşmak için yerel özelliklerle tamamlama zorunluluğunu haklı çıkarır. Buna göre, Görünürlük Yollarını performansını test ediyoruz. Yine, özellik vektörünü, Ihvgs'nin derece dağılımı  $P(k)$  ( $k = 40$ 'a kadar), Ivgs'nin derece dağılımı ( $k = 80$ 'e kadar) ve her ikisinin birleştirilmesinin ilk girişleri tarafından verilen küresel tanımlayıcılarla besliyoruz.



Şekil 3. Temel genel/yerel tanımlayıcılarla elde edilen temel  $N_{PCs}$  bileşenlerinin sayısına bağlı olarak Model ortalama sınıflandırma doğruluğu (30 model uygulaması) a) 2dhela veri kümesinde doğrusal çekirdek çok sınıflı bire bir destek vektör makinesi ve b) sadece ilk 50 sınıfın dahil edildiği Usptex'in bir alt kümesindeki kuadratik bir çekirdek Multiclass bire bir destek vektör makinesi.

Aşırı uymaktan kaçmak için, sınıflandırmadan önce özelliklerin sayısını azaltmak için PCA uygulanır. PCA dönüştürülen özellikler daha sonra doğrusal çekirdek çok sınıflı bire bir destek vektör makinesine tekrar girişte verilir. En iyi sınıflandırma doğruluğu, IHVG ve IVG tanımlayıcılarının karışımından yüzde 83.5'e ulaşan genel ve yerel özelliklerin bir kombinasyonu kullanılarak elde edilir.


## 2D HeLa Dataset

ovo-ISVM models	Accuracy	(AUC)	MAA
Global features: P(k)+PCA IVG+IHVG	75.4%	0.939	74.5%
Local features: Z + PCA IVG+IHVG	79.5%	0.961	78.6%
Global +Local (67 features) IVG+IHVG	83.5%	0.973	83%
2D Hela descriptors	N <sub>PCs</sub>	MAA	
P(k) IVG	14	57.2%	
P(k) IHVG	8	67.6%	
Z IVG	22	75.8%	
Z IHVG	23	74%	

Tablo 2. En iyi sınıflandırma doğruluğu, sınıf AUC ve model ortalama sınıflandırma doğruluğu MAA ile elde edilen lineer-çekirdek Multiclass bire bir Destek Vektör Makinesi (ovo-ISVM) sınıflandırma algoritması üzerinde 30 model gerçekleştirmeleri, görüntü görünürlük özellikleri farklı setleri için. En iyi sonuçlar, genel (derece dağılımı) ve yerel özelliklerin (görünürlük yamaları) bir karışımını kullanırken bulunur. Her tanımlayıcı için temel bileşenlerin Sayısı  $N_{PCs}$  30 model gerçekleştirmeleri üzerinde model ortalama sınıflandırma doğruluğu MMA maksimize ederek boşluk  $N_{PCs} \in [5, \dots, 25]$  ayrıntılı arama yoluyla ayarlanır.

Tablo 2'te, her tanımlayıcı kümesi için, ROC eğrisi (AUC) altındaki en iyi ortalama sınıflandırma doğruluğu ve buna karşılık gelen ortalama (sınıflar üzerinde) değerlerinin, model gerçekleştirilmesi (Model Ortalama Doğruluğu MAA) üzerinden ortalama sınıflandırma doğruluğu ile birlikte sınıflandırıcının 30'dan fazla gerçekleştirmesini elde ettiğimizi bildiriyoruz. Şekil 4'de biz en iyi model eğitimi için sınıf ait karışıklık matris ve ROC eğrileri ayrıntılarını tasvir. Karışıklık matrisindeki en yüksek çapraz dışı değerler, örneğin ER ve mitokondriyal proteinler, Golgi ve cis-Golgi proteinleri gibi ayırt edilmesi zor olan sınıf çiftlerine karşılık gelir. Her özellik seti için en uygun bilgisayar sayısı (yerel/küresel, IVG/IHVG) 30 model gerçekleştirilmesi üzerinde modelin (MAA) ortalama sınıflandırma doğruluğunu ölçerek ana bileşenler sayısı  $N_{PCs}$  [5, ... , 25] alanında kapsamlı bir arama ile bulunur (Bkz. Şekil 4a ve Tablo 2).

Her tanımlayıcı için MAA değerleri, bileşenlerin sayısını artırarak hızlı bir şekilde doygunluk eğilimindedir, yani son model NP'lerin seçimine göre sağlamdır. İlginçtir ki, IHVG'nin genel özellikleri IVG'den daha bilgilendirici olsa da, bunların IVG için IHVG'den daha bilgilendirici olduğu için, bunun tam tersi yerel özellikler için de geçerlidir. Başka bir deyişle, bir dizi spesifik olmayan grafik tabanlı özellik kullanan cimri yaklaşımımız, özel, içeriğe bağlı özellikler açısından rekabetçidir. Farkında olduğumuz en yüksek yayınlanmış performans yüzde 95,3 , bir nöral ağ sınıflandırıcı ile birlikte çok çözünürlüklü özellik çıkarma yaklaşımı ile elde edilen, ve bir soruna özel stratejiler ile burada tasarlanmış spesifik olamayan yaklaşım tamamlayarak rekabetçi sonuçlara ulaşmak olup olmadığı açık bir sorundur.



Şekil 4. IHVG ve IVG'den Genel (derece dağılımı) ve Yerel (Görünürlük Yamaları) karışımında bir kuadratik çekirdek Destek Vektör Makinesi kullanarak, 2B HeLa Dataset'in sınıflandırılması için karışıklık matrisi (panel a) ve AUCs (panel b).

### 1.4 RGB Görüntüler için Çoklu Görüntü Görünürlük Görünürlüğü:Doğal Dokular

Doğal sahnelerde, daha karmaşık dokular ortaya çıkabilir, örneğin, bir gölün yüzeyindeki dalgaların desenleri veya yukarıdan resmedildiğinde bir bitkiden yaprakların konformasyonu ve eğilimi. Bu tür dokular genellikle doğal dokular olarak sınıflandırılır ve gerçek dünya sahnelerinde ortaya çıkan daha karmaşık özelliklerin yapı taşları olarak görülebileceğinden çok ilgilidir.



Buna göre, bu alt bölümde, iyi bilinen üç doğal doku koleksiyonunu ele alıyoruz: Upstex veri kümesi, renkli Brodatz veri kümesi ve çok bantlı (MTB) veri kümesi.

Upstex veri seti, her biri duvarlar, kaldırımlar, bitki örtüsü, toprak, bitki yaprakları, kayalar gibi dış mekan sahnelerinden dokular gösteren 12 örnekten oluşan 191 sınıf içerir (şek. 1c farklı sınıflardan bazı örnekler gösteriyoruz).

Brodatz veri kümesi, doku analizi literatüründe en çok kullanılan veri kümelerinden biridir ve bir albümden taranan görüntüleri kavrar.

Veri kümesinin renkli versiyonunda, toplam 112 farklı sınıfı tanımlayan 640 x 640 boyutunda 112 görüntü vardır (şek. 1c bazı örnekler bildiriyoruz). Her sınıf için, 160 x 160 boyutunda örtüşmeyen alt görüntüler olarak tanımlanan 16 örnek vardır. Son olarak, Çoklu Bant veri kümesi, ortaya çıkan RGB görüntülerinin kanala bağlı dokuların bir karışımını (Bkz. Şekil 1c'deki bazı örnekler), toplam 154 sınıf ve sınıf başına 16 örnek gibi çeşitli kombinasyonlarda orijinal gri tonlama görüntülerinin üçüzlerini bir araya getirerek Brodatz veri kümesinden türetilmiştir. Tüm bu üç veri kümesi, RGB görüntüleri, birçok farklı sınıf ve sınıf başına nispeten az sayıda örnek içeren tarafından karakterize edilir. Buradaki yaklaşımımız her görüntüden çoklu IVG/IHVG'yi ayıklamaktır (görüntü kanallarının her birini oluşturan tek katmanlı IVG'leri/IHVG'leri ayıklayarak: R,G,B) ve her kanalın küresel/yerel özelliklerini PCA ile harmanlayarak sözde çoklayıcı tanımlayıcılar elde etmektir. 2D Hela veri kümesi için kullanılan benzer bir yöntem, ama bu sefer, tüm veri setleri için sadece bir kez alt ölçülen 30 model gerçekleştirmeleri üzerinden (MMA), modeli ortalama sınıflandırma doğruluğu optimize ederek özellikleri temel bileşenler sayısı ayarlı biz sınıflandırıcı bizim verimliliğini kanıtlamak için sadece ilk 50 sınıfları. (Şekil 3b'yi içeren Usptex veri kümesi veri kümesi takip ediyoruz çoklu yerel/genel özelliklerin her biri için bileşenlerin sayısını optimize etmek için.) Tablo 3'te, veri kümelerinin her biri için, genel, yerel ve genel+yerel çoklu özellikleri ile eğitilmiş modellerle elde edilen doğruluk, sınıf başına

ortalama AUC ve MAA değerlerini rapor ediyoruz.

ova-qSVM	Accuracy (AUC)		MAA
<i>Global multiplex features: P(k) in R,G,B + PCA</i>			
IVG+IHVG (8 PCs+12 PCs)			
Usptex	93.6%	0.9829	93.2%
Brodatz Colored	98.7%	0.9929	98.3%
Multiband	98.2%	0.9982	97.8%
<i>Local multiplex features: Z in R,G,B + PCA</i>			
IVG+IHVG (15 PCs+18 PCs)			
Usptex	94.9%	0.9952	94.3%
Brodatz Colored	98.6%	0.9967	98.3%
Multiband	99.4%	0.9994	99.2%
<i>Global + Local multiplex features</i>			
IVG+IHVG (53 features)			
Usptex	98.4%	0.9975	98%
Brodatz Colored	99.8%	0.9993	99.7%
Multiband	99.6%	0.9996	99.4%

*Tablo 3. Doğal Renk Dokular Veri Kümesi: En İyi Sınıflandırma Doğruluğu, Sınıf AUC ve Model Ortalama Sınıflandırma Doğruluğu MAA bir Quadratic-Kernel Multiclass One-vs-All Destek Vektör Makinesi (ova-qSVM) Classifier Algoritması ile elde edilen 30 Model Gerçekleştirmeleri üzerinde, Multiplex Görüntü Görünürlük Özellikleri Farklı Setleri için. Çok daha düşük performans doğrusal çekirdek SVM kullanılarak elde edilebilir.*

Usptex, Brodatz ve Multiband için en iyi sınıflandırma doğruluğumuz sırasıyla yüzde 98.4, 99.8, 99.6'dır ve IHVG ve IVG'DEN çoklu yerel ve küresel özelliklerin bir kombinasyonu olan sadece 53 özellik ile elde edilir.

## REFERANSLAR

- [1]. [https://www.researchgate.net/publication/221926613\\_Visibility\\_Algorithms\\_A\\_Short\\_Review](https://www.researchgate.net/publication/221926613_Visibility_Algorithms_A_Short_Review)
- [2]. <http://kgut.ac.ir/useruploads/1550563201478ety.pdf>
- [3]. Abe, S., and N. Suzuki (2004), *Scale-free network of earthquakes*, *Europhys. Lett.* 65, 581–586, DOI: 10.1209/epl/i2003-10108-1.
- [4]. L. Nanni, A. Lumini, and S. Brahmam, “Survey on LBP based texture descriptors for image classification,” *Expert Syst. Appl.*, vol. 39, no. 3, pp. 3634–3641, 2012.

[5]. J. Iacovacci and L. Lacasa, "Visibility Graphs for Image Processing," in *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 4, pp. 974-987, 1 April 2020, doi: 10.1109/TPAMI.2019.2891742.

[6].<https://people.eecs.berkeley.edu/~malik/papers/LM-3dtexton.pdf>

[7].[https://link.springer.com/chapter/10.1007/978-3-540-74788-8\\_17](https://link.springer.com/chapter/10.1007/978-3-540-74788-8_17)